

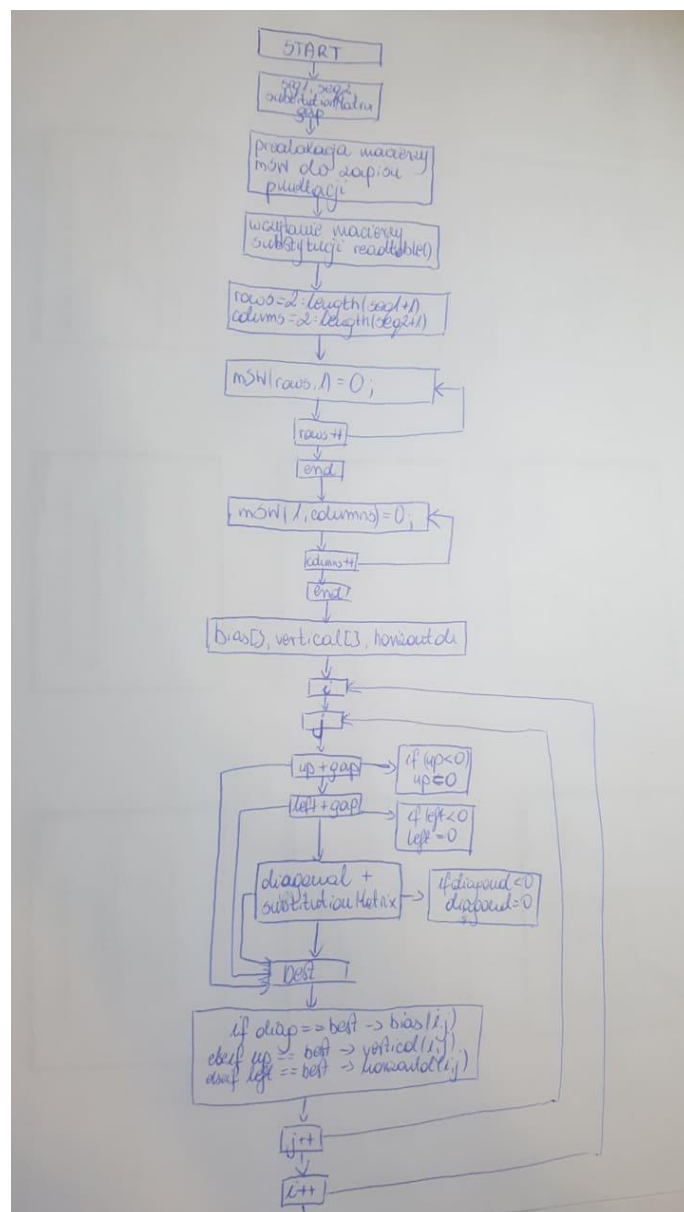
POLITECHNIKA WROCLAWSKA WYDZIAŁ PODSTAWOWYCH PROBLEMÓW TECHNIKI Laboratorium ze Wstępu do bioinformatyki		
Typ dokumentu:	Zadanie 3	Data oddania zadania: 15.04.2019
Tytuł:	Dopasowanie lokalne par sekwencji	

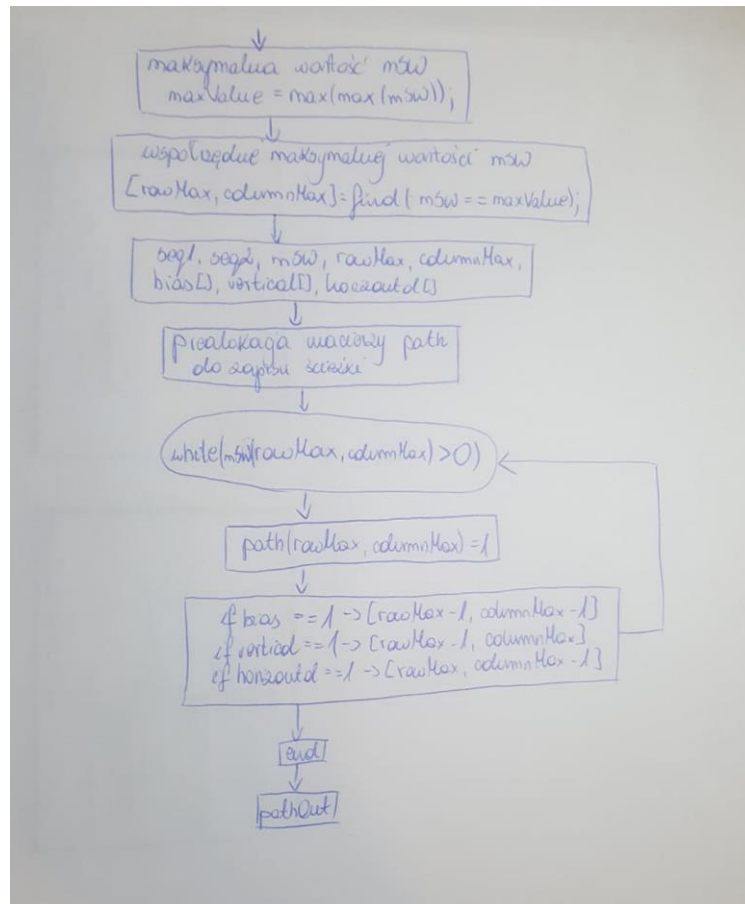
Autor: Aleksandra Brela, 229636

1. Odnosnik do repozytorium z kodem źródłowym:

<https://github.com/Abrela/LocalAlignment>

2. Schemat blokowy algorytmu dopasowania lokalnego





3. Analiza złożoności obliczeniowej algorytmu –

a. Funkcja **matrixScore()**:

```

1: function [ mSWout, coordinateRowMax, coordinateColumnMax, maxValueOut, bias, vertical, horizontal,
2: sOut ] = matrixScore( seq1, seq2, substitutionMatrix, gap )
3: N1 = length(seq1); przypisanie
4: N2 = length(seq2); przypisanie
5: mSW = zeros( N1+1, N2+1 ); prealokacja, przypisanie
6: [rows, columns] = size(mSW); przypisanie
7: s = readtable(substitutionMatrix, 'ReadRowNames', true); przypisanie
8: mSW(1,1) = 0; przypisanie
9: for i=2 to (N1+1) #(i=2, i<= (N1+1), i++) inkrementacja, iteracje
10: mSW(i,1) = 0; przypisanie
11: end
12: for j=2 to (N2+1) #(j=2, j<= (N2+1), j++) inkrementacja, iteracje
13: mSW(1,j) = 0; przypisanie
14: end
15: bias = zeros(size(mSW,1), size(mSW,2)); przypisanie
16: vertical = zeros(size(mSW,1), size(mSW,2)); przypisanie
17: vertical(2:size(vertical,1),1) = ones(size(vertical,1)-1,1); przypisanie
18: horizontal = zeros(size(mSW,1), size(mSW,2)); przypisanie
19: horizontal(1,2:size(horizontal,2)) = ones(1,size(horizontal,2)-1); przypisanie
20: currentRow = mSW(1,:); przypisanie
21: for i=2 to rows #(i=2, i<=rows, i++) inkrementacja, iteracje
22: lastRow = currentRow; przypisanie
23: currentRow = mSW(i,:); przypisanie
24: best = currentRow(1); przypisanie
  
```

```

25:for j=2 to columns#(j=2, j<=columns, j++) inkrementacja, iteracje
26:up = lastRow(j) + gap; przypisanie
27:if (up<0) warunek, porównanie
28:up = 0; przypisanie
29:end
30:left = best + gap; przypisanie, inkrementacja
31:if (left<0) warunek, porównanie
32:left = 0; przypisanie
33:end
34:if seq1(i-1) == seq2(j-1) warunek, porównanie
35:diagonal = lastRow(j-1) + s{seq1(i-1),seq2(j-1)}; przypisanie, inkrementacja
36:else
37:diagonal = lastRow(j-1) + s{seq1(i-1),seq2(j-1)}; przypisanie, inkrementacja
38:end
39:if (diagonal<0) warunek, porównanie
40:diagonal = 0; przypisanie
41:end
42:MAX = max([up, left, diagonal]); przypisanie
43:if(MAX == diagonal) warunek, porównanie
44:bias(i, j) = 1; przypisanie
45:end
46:if(MAX == up) warunek, porównanie
47:vertical(i, j) = 1; przypisanie
48:end
49:if(MAX == left) warunek, porównanie
50:horizontal(i, j) = 1; przypisanie
51:end
52:if up > left warunek, porównanie
53:best = up; przypisanie
54:else
55:best = left; przypisanie
56:end
57:if diagonal >= best warunek, porównanie
58:best = diagonal; przypisanie
59:end
60:currentRow(j) = best; przypisanie
61:end
62:mSW(i,:) = currentRow; przypisanie
63:end
64:mSWout = mSW; przypisanie
65:sOut = s; przypisanie
66:maxValue = max(max(mSW)); przypisanie
67:[coordinateRowMax,coordinateColumnMax] = find(mSW == maxValue); przypisanie
68:maxValueOut = maxValue; przypisanie
69:end

```

b. Funkcja **matchPath()**:

```

1:function [ pathOut, lengthAlignmentOut, identityOut, gapsOut, s1Out, s2Out, last ] = ...
2:matchPath(seq1, seq2, mSW, rowMax, columnMax, bias, vertical, horizontal )
3:path = zeros(size(mSW)); prealokacja, przypisanie
4:last = [rowMax, columnMax]; przypisanie
5:gaps = 0; przypisanie
6:identity = 0; przypisanie
7:s1 = ""; przypisanie
8:s2 = ""; przypisanie
9:while (mSW(last(1),last(2)) > 0) warunek, porównanie
10:path(last(1),last(2)) = 1; przypisanie
11:diagonal = bias(last(1),last(2)); przypisanie

```

```

12:left = vertical(last(1),last(2)); przypisanie
13:up = horizontal(last(1),last(2)); przypisanie
14:if(diagonal == 1) warunek, porównanie
15:last = [last(1)-1,last(2)-1]; przypisanie, inkrementacja
16:identity = identity+1; przypisanie, inkrementacja
17:s1 = strcat(s1, seq1(last(1))); przypisanie, inkrementacja
18:s2 = strcat(s2, seq2(last(2))); przypisanie, inkrementacja
19:else
20:if(left == 1 || up == 0) warunek, porównanie
21:last = [last(1)-1,last(2)]; przypisanie, inkrementacja
22:gaps = gaps+1; przypisanie, inkrementacja
23:s1 = strcat(s1, seq1(last(1))); przypisanie, inkrementacja
24:s2 = strcat(s2, '-'); przypisanie, inkrementacja
25:end
26:if(left == 0 || up == 1) warunek, porównanie
27:last = [last(1),last(2)-1]; przypisanie, inkrementacja
28:gaps = gaps+1; przypisanie, inkrementacja
29:s1 = strcat(s1, '-'); przypisanie, inkrementacja
30:s2 = strcat(s2, seq2(last(2))); przypisanie, inkrementacja
31:end
32:end
33:end
34:pathOut = path; przypisanie
35:identityOut = identity; przypisanie
36:gapsOut = gaps; przypisanie
37:s1Out = fliplr(s1); przypisanie
38:s2Out = fliplr(s2); przypisanie
39:[r, c] = size(path); przypisanie
40:lengthAlignment = 0; przypisanie
41:for m = 1:r inkrementacja, iteracje
42:for n = 1:c inkrementacja, iteracje
43:if (path(m,n) == 1) warunek, porównanie
44:lengthAlignment = lengthAlignment+1; przypisanie, inkrementacja
45:end
46:end
47:end
48:lengthAlignmentOut = lengthAlignment; przypisanie
49:end

```

4. Porównanie przykładowych par sekwencji:

a. ewolucyjnie powiązanych

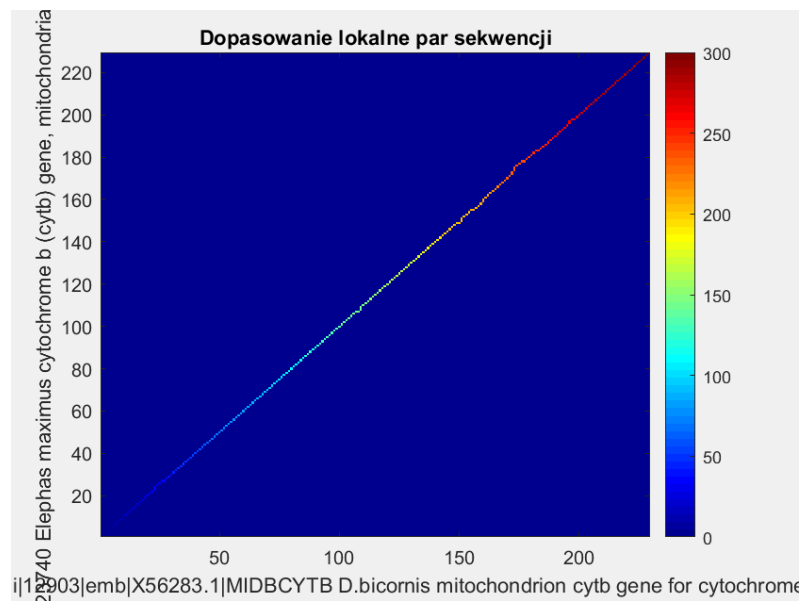
Rhino – Mastodon

```
# 1: GAAATTTTGGCTCTCTACTAGGAATCTGCCTAATCCTACAAATCCTAACCGGACTATTTCCTTGCTATACA
# 2: GAAATTTTCGGCTCACTACTAGGAGCATGCCTAATTACCCAAATCCTAACAGGATTATTCTTAGCCATACA
# Mode: distance
# Substitution matrix:
      2    -7    -5    -7
     -7     2    -7    -5
     -5    -7     2    -7
     -7    -5    -7     2
# Gap: -1
# Score: 296
# Length: 233 |
# Identity: 184/233 ( 79%)
# Gaps: 88/233 ( 38%)
GAAATTTT-GGCTCT-TCTACTAGGA-A-T-CTGCCTAAT-C-C-T-ACAAATCCTAAC-CGGA-CTATT-TCT-T
|||||_|||_|_|||_|_|||_|_|||_|_|||_|_|||_|_|||_|_|||_|_|||_|_|||_|_|||_|_|||_|_
GAAATTTT-CGGCTCA-CTACTAGGAG-C-A-TGCCTAATT-A-C-C-CAAATCCTAACA-GGAT-TATTC-CTA-
```

```
>>Rhino gi|12903|emb|X56283.1|MIDBCYTB D.bicornis mitochondrion cytb gene fr
GAAATTT-TGGCTC-TCTACTAGGA-A-T-CTGCCTAAT-C-C-T-ACAAATCCTAAC-CGGA-CTATT-TCT-T

>>NorthAmericanMastodon gi|924716|gb|U23737.1|MAU23737 Mammut americanum cy
GAAATTTT-CGGTCA-CTACTAGGAG-C-A-TGCCTAATT-A-C-C-CAAATCCTAAC-A-GGAT-TATTC-CTA-
```

Rhino – Asiatic Elephant




Mastodon – Asiatic Elephant

```
# 1: GAAATTTTCGGCTCACTACTAGGAGCATGCCTAATTACCCAAATCCTAACAGGATTATTCCTAGCCATACATTA-
# 2: GAAATTTTCGGCTCACTACTAGGAGCGTGCCTAATTACCCAAATCCTAACAGGATTATTCCTAGCCATACATTA-
# Mode: distance
# Substitution matrix:
      2    -7    -5    -7
    -7     2    -7    -5
    -5    -7     2    -7
    -7    -5    -7     2
# Gap: -1
# Score: 400
# Length: 228
# Identity: 214/228 ( 94%)
# Gaps: 28/228 ( 12%)
GAAATTTTCGGCTCACTACTAGGAGC-ATGCCTAATTACCCAAATCCTAACAGGATTATTCCTAGCCATACATTA-
|||||
GAAATTTTCGGCTCACTACTAGGAGCG-TGCCTAATTACCCAAATCCTAACAGGATTATTCCTAGCCATACATTAC-

|>>NorthAmericanMastodon gi|924716|gb|U23737.1|MAU23737 Mammut americanum cy
GAAATTTTCGGCTCACTACTAGGAGC-ATGCCTAATTACCCAAATCCTAACAGGATTATTCCTAGCCATACATTA-

>>AsiaticElephant gi|924712|gb|U23740.1|EMU23740 Elephas maximus cytochrome
GAAATTTTCGGCTCACTACTAGGAGCG-TGCCTAATTACCCAAATCCTAACAGGATTATTCCTAGCCATACATTAC
```



b. ewolucyjnie niepowiązanych

Human – Mastodon

```
# 1: GAAATTTTCGGCTCACTACTAGGAGCATGCCTAATTACCCAAATCCTAACAGGATTATTCCTAGCCATACA
# 2: ATGACCCCAATACGCAAAATTAACCCCTAATAAAATTAATTAACCACTCATTTCATCGACCTCCCCACCC
# Mode: distance
# Substitution matrix:
    2   -7   -5   -7
   -7    2   -7   -5
   -5   -7    2   -7
   -7   -5   -7    2
# Gap: -1
# Score: 248
# Length: 236
# Identity: 174/236 ( 74%)
# Gaps: 104/236 ( 44%)
GAAA-TTTCGGCTCACT-ACT-AGG-AGC-ATGCCT-AAT-T-A-CCCAAATC-CT-AACAGGA-TTATTCCTAG
||||_||||_||||_||_||_||_||||_||_||_||||_||_||_||||_||_||_||||_||_||_||||_||
GAAAC-TTCGGCTCACTC-CTT-GGC-GCC-TGCCTG-ATC-C-T-CCAAATCAC-C-ACAGGAC-TATTCCTAG

# 1: GAAATTTTCGGCTCACTACTAGGAGCATGCCTAATTACCCAAATCCTAACAGGATTATTCCTAGCCATACA
# 2: ATGACCCCAATACGCAAAATTAACCCCTAATAAAATTAATTAACCACTCATTTCATCGACCTCCCCACCC
# Mode: distance
# Substitution matrix:
    2   -7   -5   -7
   -7    2   -7   -5
```

```

-5      -7      -7
-7      -5      -7      2
# Gap: -1
# Score: 248
# Length: 238
# Identity: 175/238 ( 74%)
# Gaps: 106/238 ( 45%)
GAAA-TTTCGGCTCACT-ACT-AGG-AGC-ATGCCT-AAT-T-A-CCCAAATC-CT-AACAGGA-TTATTCCTAG
||||_|||||||_||_||_||_||||_||_____||||||_|_|||||_|
GAAAC-TTCGGCTCACTC-CTT-GGC-GCC-TGCCTG-ATC-C-T-CCAAATCAC-C-ACAGGAC-TATTCCTAG

# 1: GAAATTTCGGCTCACTACTAGGAGCATGCCTAATTACCCAAATCCTAACAGGATTATTCCTAGCCATAC
# 2: ATGACCCCAATACGCAAAATTAACCCCTAATAAAATTAATTAACCACTCATTTCATCGACCTCCCCACC
# Mode: distance |
# Substitution matrix:
      2      -7      -5      -7
-7      2      -7      -5
-5      -7      2      -7
-7      -5      -7      2
# Gap: -1
# Score: 248
# Length: 242
# Identity: 176/242 ( 73%)
# Gaps: 108/242 ( 45%)
GAAA-TTTCGGCTCACT-ACT-AGG-AGC-ATGCCT-AAT-T-A-CCCAAATC-CT-AACAGGA-TTATTCCTAG
||||_|||||||_||_||_||_||||_||_____||||||_|_|||||_|
GAAAC-TTCGGCTCACTC-CTT-GGC-GCC-TGCCTG-ATC-C-T-CCAAATCAC-C-ACAGGAC-TATTCCTAG

>>NorthAmericanMastodon gi|924716|gb|U23737.1|MAU23737 Mammut americanum cy
GAAA-TTTCGGCTCACT-ACT-AGG-AGC-ATGCCT-AAT-T-A-CCCAAATC-CT-AACAGGA-TTATTCCTAG

>>human cytochrome b
GAAAC-TTCGGCTCACTC-CTT-GGC-GCC-TGCCTG-ATC-C-T-CCAAATCAC-C-ACAGGAC-TATTCCTAG


>>NorthAmericanMastodon gi|924716|gb|U23737.1|MAU23737 Mammut americanum cy
GAAA-TTTCGGCTCACT-ACT-AGG-AGC-ATGCCT-AAT-T-A-CCCAAATC-CT-AACAGGA-TTATTCCTAG

>>human cytochrome b
GAAAC-TTCGGCTCACTC-CTT-GGC-GCC-TGCCTG-ATC-C-T-CCAAATCAC-C-ACAGGAC-TATTCCTAG

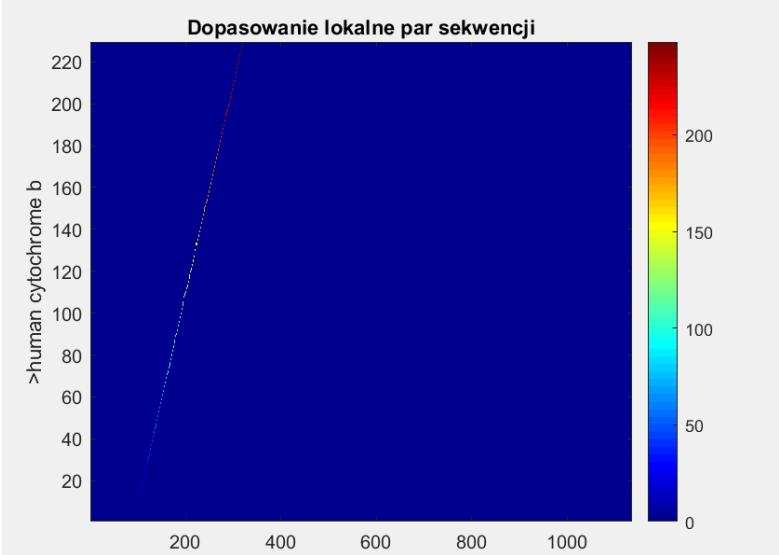
>>NorthAmericanMastodon gi|924716|gb|U23737.1|MAU23737 Mammut americanum cy
GAAA-TTTCGGCTCACT-ACT-AGG-AGC-ATGCCT-AAT-T-A-CCCAAATC-CT-AACAGGA-TTATTCCTAG

>>human cytochrome b
GAAAC-TTCGGCTCACTC-CTT-GGC-GCC-TGCCTG-ATC-C-T-CCAAATCAC-C-ACAGGAC-TATTCCTAG


```

7.1|MAU23737 Mammut americanum cytochrome b (cytb) gene, mitochondrial gene e



7.1|MAU23737 Mammut americanum cytochrome b (cytb) gene, mitochondrial gene e




7.1|MAU23737 Mammut americanum cytochrome b (cytb) gene, mitochondrial gene e

Human – Asiatic Elephant

```
# 1: GAAATTTTCGGCTCACTACTAGGAGCGTGCCTAATTACCCAAATCCTAACAGGATTATTCCTAGCCATACA
# 2: ATGACCCCAATACGCAAAATTAACCCCTAATAAAATTAATTAACCACTCATTTCATCGACCTCCCCACCC
# Mode: distance
# Substitution matrix:
      2    -7    -5    -7
     -7     2    -7    -5
     -5    -7     2    -7
     -7    -5    -7     2
# Gap: -1
# Score: 250
# Length: 253
# Identity: 178/253 ( 70%)
# Gaps: 118/253 ( 47%)
GAAA-TTTCGGCTCACT-ACT-AGG-AGC-GTGCCT-AAT-T-A-CCCAAATC-CT-AACAGGA-TTATTCCTAG
||||_|||||_||||_||_||_||_||||_||_||_||||_|||||_||_||||_|||||_|||||_
GAAAC-TTCGGCTCACTC-CTT-GGC-GCC-TGCCTG-ATC-C-T-CCAAATCAC-C-ACAGGAC-TATTCCTAG

>>AsiaticElephant gi|924712|gb|U23740.1|EMU23740 Elephas maximus cytochrome
GAAA-TTTCGGCTCACT-ACT-AGG-AGC-GTGCCT-AAT-T-A-CCCAAATC-CT-AACAGGA-TTATTCCTAG

>>human cytochrome b
GAAAC-TTCGGCTCACTC-CTT-GGC-GCC-TGCCTG-ATC-C-T-CCAAATCAC-C-ACAGGAC-TATTCCTAG
```



Human – Rhino

```
# 1: GAAATTTTGGCTCTCTACTAGGAATCTGCCTAATCCTACAAATCCTAACCGGACTATTTCTTGCTATACF
# 2: ATGACCCCAATACGCAAAATTAACCCCTAATAAAATTAATTAACCACTCATTCATCGACCTCCCCACCC
# Mode: distance
# Substitution matrix:
      2    -7    -5    -7
    -7     2    -7    -5
    -5    -7     2    -7
    -7    -5    -7     2
# Gap: -1
# Score: 264
# Length: 229
# Identity: 179/229 ( 78%)
# Gaps: 94/229 ( 41%)
GAAA-TTT-TGGCTC-TCT-ACT-AGG-A-A-TCTGCCT-AATCCT-ACAAATC-CT-AAC-CGGACTATT-TCT
||||_||_||||_||_||_||_||_||||_||||_||||_||_||_||||_||_||
GAAAC-TTC-GGCTCA-CTC-CTT-GGC-G-C-CTGCCTG-ATCCTC-CAAATCAC-C-ACA-GGACTATT-CI

# 1: GAAATTTTGGCTCTCTACTAGGAATCTGCCTAATCCTACAAATCCTAACCGGACTATTTCTTGCTATACF
# 2: ATGACCCCAATACGCAAAATTAACCCCTAATAAAATTAATTAACCACTCATTCATCGACCTCCCCACCC
# Mode: distance
# Substitution matrix:
      2    -7    -5    -7
    -7     2    -7    -5
    -5    -7     2    -7
    -7    -5    -7     2
# Gap: -1
# Score: 264
# Length: 231
# Identity: 180/231 ( 78%)
# Gaps: 96/231 ( 42%)
GAAA-TTT-TGGCTC-TCT-ACT-AGG-A-A-TCTGCCT-AATCCT-ACAAATC-CT-AAC-CGGACTATT-TCT
||||_||_||||_||_||_||_||_||||_||||_||||_||_||_||||_||_||
GAAAC-TTC-GGCTCA-CTC-CTT-GGC-G-C-CTGCCTG-ATCCTC-CAAATCAC-C-ACA-GGACTATT-CI

# 1: GAAATTTTGGCTCTCTACTAGGAATCTGCCTAATCCTACAAATCCTAACCGGACTATTTCTTGCTATACF
# 2: ATGACCCCAATACGCAAAATTAACCCCTAATAAAATTAATTAACCACTCATTCATCGACCTCCCCACCC
# Mode: distance
# Substitution matrix:
      2    -7    -5    -7
    -7     2    -7    -5
    -5    -7     2    -7
    -7    -5    -7     2
# Gap: -1
# Score: 264
# Length: 235
# Identity: 181/235 ( 77%)
# Gaps: 98/235 ( 42%)
GAAA-TTT-TGGCTC-TCT-ACT-AGG-A-A-TCTGCCT-AATCCT-ACAAATC-CT-AAC-CGGACTATT-TCT
||||_||_||||_||_||_||_||_||||_||||_||||_||_||_||||_||_||
GAAAC-TTC-GGCTCA-CTC-CTT-GGC-G-C-CTGCCTG-ATCCTC-CAAATCAC-C-ACA-GGACTATT-CI
```

```
>>Rhino gi|12903|emb|X56283.1|MIDBCYTB D.bicornis mitochondrion cytb gene fa
GAAA-TTT-TGGCTC-TCT-ACT-AGG-A-A-TCTGCCT-AATCCT-ACAAATC-CT-AAC-CGGACTATT-TCT-

>>human cytochrome b
GAAAC-TTC-GGCTCA-CTC-CTT-GGC-G-C-CTGCCTG-ATCCTC-CAAATCAC-C-ACA-GGACTATTC-CT-

>>Rhino gi|12903|emb|X56283.1|MIDBCYTB D.bicornis mitochondrion cytb gene fa
GAAA-TTT-TGGCTC-TCT-ACT-AGG-A-A-TCTGCCT-AATCCT-ACAAATC-CT-AAC-CGGACTATT-TCT-

>>human cytochrome b
GAAAC-TTC-GGCTCA-CTC-CTT-GGC-G-C-CTGCCTG-ATCCTC-CAAATCAC-C-ACA-GGACTATTC-CT-

>>Rhino gi|12903|emb|X56283.1|MIDBCYTB D.bicornis mitochondrion cytb gene fa
GAAA-TTT-TGGCTC-TCT-ACT-AGG-A-A-TCTGCCT-AATCCT-ACAAATC-CT-AAC-CGGACTATT-TCT-

>>human cytochrome b
GAAAC-TTC-GGCTCA-CTC-CTT-GGC-G-C-CTGCCTG-ATCCTC-CAAATCAC-C-ACA-GGACTATTC-CT-
```

